Q1.

状态s1

从s1向上s3时，s3:R(s1,上,s3)=0

从s1向右s2时，s2:R(s1,右,s2)=0

初始策略为向上移动，所以：

V(s1)=R(s1,上,s3)+γV(s3)

V(s1)=0+γV(s3)

V(s1)=0.99×V(s3)

状态s2

从s2向上s4时,s4:R(s2,上,s4)=1

从s2向右sd时,sd:R(s2,右,sd)=－1

初始策略为向上移动，所以：

V(s2)=R(s2,上,s4)+γV(s4)

V(s2)=1+0

V(s2)=1

状态s3

从s3向上sd时,sd:R(s3,上,sd)=－1

从s3向上s4时,s4:R(s3,右,s4)=1

初始策略为向上移动，所以：

V(s3)=R(s3,上,sd)+γV(sd)

V(s3)=－1+0

V(s3)=－1

但这时从s3向右移动的获得价值更高，所以：

V(s3)=R(s3,右,s4)+γV(s4)

V(s3)=1+0

V(s3)=1

代入V(s3)计算V(s1)：

V(s1)=0.99×1=0.99

最终价值为：

V(s1)=0.99

V(s2)=1

V(s3)=1

Q2.

优化状态s3的策略为:

初始状态下，每个状态的价值函数都初始化为0：V(s1)=0,V(s2)=0,V(s3)=0

这时计算状态s3的行为价值函数Q(s3,a)为

从s3向上移动：

到达下一个状态时，sd：奖励R=－1，下一个状态价值V(sd)=0

Q(s3,上)=R(s3,上,sd)+γV(sd)=－1+0.99×0=－1

从s3向右移动：

到达下一个状态时，s4：奖励R=1，下一个状态价值V(sd)=0

Q(s3,右)=R(s3,右,s4)+γV(s4)=1+0.99×0=1

选择最优行为

Q(s3,上)=－1

Q(s3,右)=1

因为Q(s3,右)>Q(s3,上)，所以从s3向右移动时更优的行为。

因此，需要将状态s3的策略优化为向右移动。

所以优化后的状态s3的策略为：从s3向右移动

通过这一过程，可以优化智能体在状态s3的策略。

Q3.

Q3.

Q-Learning算法:

更新 $q_\pi(s,a) \leftarrow q_\pi(s,a) + \alpha[R + \gamma \max_{a'} q_\pi(s',a') - q_\pi(s,a)]$

执行一个具体的过程为:

在初始状态下, 所有动作-价值函数值为

0.1/0	0/0
0.1/0	0.1/0

这时每个状态可能动作, 并进行更新的话.

1. 从 s_1 开始 跟据初始策略 向上转移动力 s_3
2. 奖励 $R(s_1, 上, s_3) = 0$ (由greed上的移动, 没奖励)
3. $\gamma = 0.99$

这时 s_3 的最大Q值为 $\max(0.1, 0) = 0.1$

计算Q值.

$Q(s_1, 上) \leftarrow Q(s_1, 上) + 0.5[0 + 0.99 \times 0.1 - 0.1]$

$Q(s_1, 上) \leftarrow 0.1 + 0.5[0.099 - 0.1]$

$Q(s_1, 上) \leftarrow 0.0995$

更新后状态为

0.0995/0	0/0
0.1/0	0.1/0

s_1: 向上 (Q值大)

s_2: 向上 (0.1/0)

s_3: 向上 (0.1/0) s_4: 不需要.

上/上	上/上
上/上	上/上