课程：人工智能 **作业 3**

北航软件学院

学期：2024，春季 提交截止时间：2024年6月1日，11：59 PM

提醒注意：

- 本次作业发布于2024年5月12日，截止于2024年6月1日。
- 作业三分为三部分：问答题、实训题、以及实训题报告
  - 问答题答案可以手写并扫描，或者用latex（或word）手打，最终以QA.pdf文件命名。
  - 实训题按照项目共享链接内要求和基础代码进行作答。
  - 报告部分同样可以手写或者手打，以Report.pdf文件命名。
  - 作业提交格式：$< studentID >_< name >$_A3.zip。比如ZY1921102_田嘉怡_A3.zip
  - 提交的zip文件要求（仅）包括：
    - 实训题文件：main.ipynb
    - 问答题答案：QA.pdf
    - 报告：Report.pdf
- 作业压缩包需要在spoc平台上提交。
- 每迟交1天（不满1天按1天计算），本次作业扣除10%分数。
- 不按作业要求和格式提交，视情况扣分。不得抄袭。

第一部分：问答题（共8分）

Q 1

说明在K-均值聚类算法执行过程中，其目标函数 $\sum_{i=1}^{K}\sum_{x\in G_i}||x-c_i||^2$ 是严格递减的，并解释为什么K-均值聚类算法可以确保在有限步内收敛。

Q 2

请回答以下关于自编码器相关问题。

1) 最小化重构误差的思想可以引申到（深度）自编码器。当采用一层线性编码器和一层线性解码器的自编码器结构，并用梯度下降法通过最小化重构误差目标函数对编解码器参数进行优化时，其结果跟PCA得到的结果是否相同？为什么？

2) 变分自动编码器与传统自动编码器相比具有什么特点？请解释变分自动编码器如何实现潜在空间的连续性和可解释性。

Q 3

给定N个独立同分布数据，$X=\{x_1,...,x_N\}$表示观测变量，$Z=\{z_1,...,z_N\}$表示相应的隐藏变量。概率模型假设两个变量的联合分布为$p(X,Z)$，目标是找到后验分布以$p(Z|X)$及边缘分布$p(X)$ 的近似。证明观测数据X的对数边缘分布 $\ln p(X)$ 可以分解为：

$$\ln p(X)=\mathcal{L}(q)+KL(q||p)$$

两个项，其中

$$\mathcal{L}(q)=\int q(Z)\ln\{\frac{p(X,Z)}{q(Z)}\}dZ,$$

$$KL(q||p) = -\int q(Z)\ln\{\frac{p(Z|X)}{q(Z)}\}dZ$$

Q 4
请回答以下关于视觉内容生成模型相关问题。

1) 扩散模型不仅可以用于生成图像，还可以应用于其他领域。请举例说明扩散模型在自然语言处理、音乐生成或视频生成等方面的应用场景，并讨论其优势和挑战。

2) 评估视觉内容生成模型的质量是一个重要的任务。如何定量评估生成图像的质量？请描述一种常用的评估指标，并解释其原理。

Q 5
生成式大语言模型（如GPT-4等）如何处理超长的文本，例如128k的文本输入？请给出几个实际应用中具体的策略。

第二部分：实训题（共5分）

实训题要求:

- 本次作业包括1个实训题，作业要求以及基础代码以Aistudio项目的形式发布。
- 发布项目链接永久有效，不再有3天之内fork的限制。

Q 1 生成式模型基础

生成式模型是一类机器学习模型，其主要目的是生成具有与训练数据相似性质的新样本。这些模型通过学习数据的统计规律和潜在结构，能够生成具有类似于训练数据的新数据。

本实验要求使用PaddlePaddle，实现简单的AutoEncoder, VAE和扩散模型，填写相应代码。实验介绍详情和参考基础代码请参见Aistudio中的共享项目“人工智能课程-作业三-生成式模型”。

第三部分：实训题实验报告（共2分）

- 请按照实验报告模板完成实验报告。
- 实验报告模板是通用模板，可根据每个作业要求的差别，自由进行微调。